Statistika pro informatiku

Souhrn látky

únor 2014

Obsah

1 Základy statistiky a pravděpodobnosti

1.1 Pravděpodobnost jevu a jeho doplňku

$$\mathbb{P}(A) = \frac{size(A)}{size(\Omega)}$$

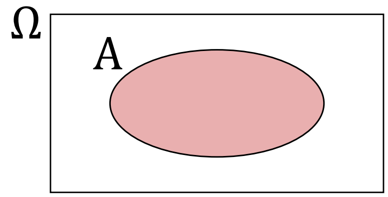

Obrázek 1: Vennův diagram základní pravděpodobnosti jevu

$$\mathbb{P}\left(A^C\right) = 1 - \mathbb{P}(A)$$

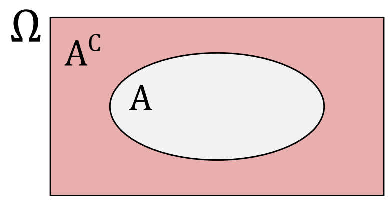

Obrázek 2: Vennův diagram doplňku jevu

1.2 Sjednocení jevů

Pro disjunktní jevy platí

$$\mathbb{P}(A \cup B) = \mathbb{P}(A) + \mathbb{P}(B).$$

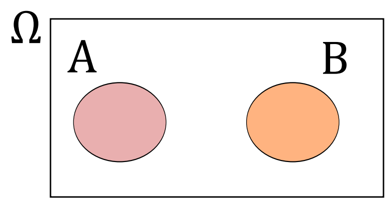

Obrázek 3: Dva disjunktní jevy

Jinak obecně platí (pro nedisjunktní jevy):

$$\mathbb{P}(A \cup B) = \mathbb{P}(A) + \mathbb{P}(B) - \mathbb{P}(A \cap B).$$

Oblast průniku by byla započítána dvakrát, proto je potřeba ji odečíst.

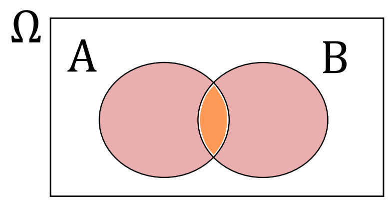

Obrázek 4: Sjednocení nedisjunktních jevů

1.3 Průnik jevů

$$\begin{aligned}
\mathbb{P}(A \cap B) &= \mathbb{P}(A|B)\,\mathbb{P}(B) \\
\mathbb{P}(A \cap B) &= \mathbb{P}(B|A)\,\mathbb{P}(A) \\
\mathbb{P}(A \cap B \cap C \ldots) &= \mathbb{P}(A)\,\mathbb{P}(B|A)\,\mathbb{P}(C|A \cap B)\ldots \\
\mathbb{P}(A \cap B \cap C \ldots) &= \mathbb{P}(A|B \cap C)\,\mathbb{P}(B|C)\,\mathbb{P}(C)
\end{aligned}$$

Obecně zapsáno:

$$\mathbb{P}(\text{intersection}) = \mathbb{P}(\text{event}|\text{condition}) * \mathbb{P}(\text{condition})$$

1.4 Nezávislost jevů

U nezávislých jevů platí

$$\begin{aligned}
\mathbb{P}(A|B) &= \mathbb{P}(A) \\
\mathbb{P}(B|A) &= \mathbb{P}(B),
\end{aligned}$$

a proto tedy:

$$\boxed{\mathbb{P}(A \cap B) = \mathbb{P}(A) * \mathbb{P}(B)}.$$

Pokud jsou dva jevy X a Y **spojité a nezávislé**, pak

$$\mathbb{P}(X = Y) = 0.$$

Pokud jsou dva jevy X a Y **stejně rozdělené a nezávislé**, pak

$$\mathbb{P}(X < Y) = \mathbb{P}(Y < X).$$

1.5 Podmíněná pravděpodobnost

$$\mathbb{P}(A|B) = \frac{\mathbb{P}(A \cap B)}{\mathbb{P}(B)}, \mathbb{P}(B) \neq 0$$

„Pravděpodobnost jevu A za podmínky, že jsme v B a že jev B nastal.“

$$\mathbb{P}(A|B) = \mathbb{P}(B|A) * \mathbb{P}(A)$$

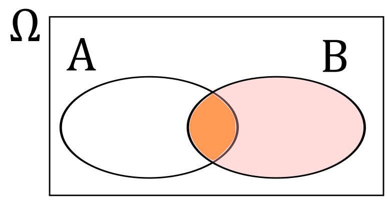

Obrázek 5: Podmíněná pravděpodobnost

1.6 Pravděpodobnostní míra

Pravděpodobnostní míra Q:

$$Q(A) = P(A|C)$$

Platí

$$\begin{aligned} 0 &\leq Q(A) \leq 1 \\ Q(A) &= 1 \\ Q\left(\bigcup_{i=1}^{\infty} A_i\right) &= \sum_{i=1}^{\infty} Q(A_i), \text{ pokud jsou } A_i \text{ disjunktní jevy} \end{aligned}$$

1.7 Bayessova věta

$$\mathbb{P}(A|B) = \frac{\mathbb{P}(B|A)\,\mathbb{P}(A)}{\mathbb{P}(B)}$$

$$\mathbb{P}(\text{♂} \cap \bullet) = \mathbb{P}(\bullet|\text{♂}) * \mathbb{P}(\text{♂}) = \mathbb{P}(\text{♂}) * \mathbb{P}(\bullet|\text{♂}) = 0,7 * 0,2 = \underline{\underline{0,14}}$$

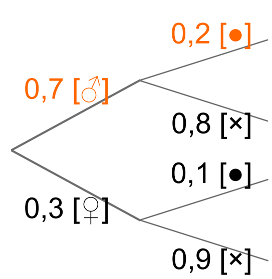

Obrázek 6: Bayessova věta pomocí stromu

1.8 Shrnutí

Jev	**Sjednocení** ($\cup$)	**Průnik** ($\cap$)
Disjunktní jevy	$\mathbb{P}(A \cup B) = \mathbb{P}(A) + \mathbb{P}(B)$	$\mathbb{P}(A \cap B) = \emptyset$
Nedisjunktní jevy	$\mathbb{P}(A \cup B) = \mathbb{P}(A) + \mathbb{P}(B) - \mathbb{P}(A \cap B)$	$\mathbb{P}(A \cap B) = \mathbb{P}(A) + \mathbb{P}(B) - \mathbb{P}(A \cup B)$
Závislé jevy	$\mathbb{P}(A \cup B) = \mathbb{P}(A) + \mathbb{P}(B) - \mathbb{P}(A \cap B)$	$\mathbb{P}(A \cap B) = \mathbb{P}(A \vert B) * \mathbb{P}(B)$
Nezávislé jevy	$\mathbb{P}(A \cup B) = \mathbb{P}(A) + \mathbb{P}(B) - \mathbb{P}(A \cap B)$	$\mathbb{P}(A \cap B) = \mathbb{P}(A) * \mathbb{P}(B)$

Tabulka 1: Shrnutí operací nad různými jevy

2 Vlastnosti

2.1 Střední hodnota $\mathbb{E}X$

Pro diskrétní veličiny

$$\mathbb{E}X = \sum_i p_i x_i = \sum_i x_i * \mathbb{P}(X = x_i)$$

Pro spojité veličiny

$$\mathbb{E}X = \int_{-\infty}^{+\infty} x * f_x(x)\,\mathrm{d}x$$

(P a f jsou funkce hustoty.)

Pro libovolné náhodné veličiny platí:

$$\begin{aligned}
\mathbb{E}(aX+Y) &= a\mathbb{E}(X) + \mathbb{E}(Y) \text{ (linearita)} \\
\mathbb{E}(X \pm Y) &= \mathbb{E}(X) \pm \mathbb{E}(Y) \\
\mathbb{E}(X+Y) &= \mathbb{E}(max\{X, Y\}) + \mathbb{E}(min\{X, Y\}) \\
\mathbb{E}X^2 &= \sum_i p_i x_i^2 \text{ (pro diskrétní jevy)} \\
\mathbb{E}(\max\{X, Y\}) &= \mathbb{E}(X) + E(Y) - \mathbb{E}(\min\{X, Y\}) \\
\mathbb{E}(XY) &= \mathbb{E}X * \mathbb{E}Y \text{ (platí jen pro nezávislé jevy)}
\end{aligned}$$

2.2 Rozptyl

Pro diskrétní náhodnou veličinu jej můžeme definovat vztahem:

$$\sigma^2 = \sum_{i=1}^{n} [x_i - E(X)]^2 p_i = \sum_{i=1}^{n} x_i^2 p_i - [E(X)]^2$$

Pro spojitou náhodnou veličinu definujeme rozptyl vztahem:

$$\sigma^2 = \int_{-\infty}^{+\infty} [x_i - E(X)]^2 f(x)\,\mathrm{d}x = \int_{-\infty}^{+\infty} x_i^2 f(x)\,\mathrm{d}x - [E(X)]^2$$

Dále platí:

$$\begin{aligned}
var\left(X\right) &= E\left[\left(X-E\left(X\right)\right)^{2}\right]=E\left(X^{2}\right)-\left(E\left(X\right)\right)^{2}\\
var\left(X\right) &= cov\left(X,\,X\right)\\
var\left(aX\right) &= a^{2}var\left(X\right)\\
var\left(X+a\right) &= var\left(X\right)\\
var\left(X\pm Y\right) &= var\left(X\right)+var\left(Y\right)\pm2cov\left(X,\,Y\right)
\end{aligned}$$

2.3 Distribuční funkce

- Funkce je zprava spojitá.

Distribuční funkce pro diskrétní veličiny

$$F = \mathbb{P}(X\leq x_{i})=\sum_{x_{i}\leq x}p_{x}\left(x_{i}\right)$$

Distribuční funkce pro spojité veličiny

$$F=\mathbb{P}(X\leq x_{i})=\int\limits_{-\infty}^{x}f_{x}\left(u\right)\mathrm{d}u\;\forall x\in\mathbb{R}$$

(X je náhodná veličina, x_i je číslo)

2.4 Hustota

Funkce hustoty pro diskrétní veličiny

$$p\left(X\right)=\mathbb{P}\left(X=x\right)$$

Funkce hustoty pro spojité veličiny

$$f\left(x\right)=F_{x}^{\prime}(x)$$

2.5 Kovariance

$$cov\left(X,\,Y\right)=E\left[\left(X-E\left(X\right)\right)*\left(Y-E\left(Y\right)\right)\right]=E\left(XY\right)-E\left(X\right)E\left(Y\right)$$

Platí, že pokud

$$cov\left(X,\,Y\right)=0$$

pak

$$E\left(XY\right)=E\left(X\right)*E\left(Y\right)$$

a X a Y jsou nezávislé.

2.6 Korelační koeficient

$$\rho\left(X,\,Y\right)=\frac{cov\left(X,\,Y\right)}{\sigma_{x}*\sigma_{y}}=\frac{cov\left(X,\,Y\right)}{\sqrt{var\left(X\right)}*\sqrt{var\left(Y\right)}}$$

3 Rozdělení pravděpodobnosti

Distribuční funkce	$X \leq k$
Hustota	$X = k$
Funkce přežití	$X > k$

Tabulka 2: Funkce

3.1 Diskrétní (nespojité) rozdělení

Diskrétní veličiny mohou nabývat pouze spočetného počtu hodnot (i nekonečného).

Rozdělení	**Funkce hustoty**	**Distribuční funkce**	$\mathbb{E}X$	$varX$
Bernoulliho, $X \sim Be(p)$	$\mathbb{P}(0) = 1 - p$, $\mathbb{P}(1) = p$	$\times$	p	$p(1-p)$
Binomické, $X \sim Bi(n,\ p)$	$\binom{n}{k} p^k (1-p)^{n-k}$	$I_{1-p}(n-k,\ 1+k)$	$\mathbb{E}X = n * p$	$varX = np(1-p)$
Geometrické, $X \sim geom(p)$	$(1-p)^{k-1} * p$	$\mathbb{P}(T \leq n) = 1 - (1-p)^n$ $\mathbb{P}(T > n) = (1-p)^n$	$\mathbb{E}X = \frac{1}{p}$	$varX = \frac{1-p}{p^2}$
Poissonovo, $X \sim Pois(\lambda)$	$\frac{\lambda^k}{k!} e^{-\lambda}$	$Q(\lfloor k+1 \rfloor,\ \lambda)$	λ	λ

Obrázek 7: Diskrétní rozdělení

3.2 Spojité rozdělení

Spojité náhodné veličiny nabývají na rozdíl od diskrétních veličin nějakého intervalu.

Rozdělení	**Funkce hustoty**	**Distribuční funkce**	$\mathbb{E}X$	$varX$
Rovnoměrné, $X \sim Unif(a,b)$	$\frac{1}{b-a};\ x \in [a,b]$	$\times$	$\frac{a+b}{2}$	$\frac{(b-a)^2}{12}$
Exponenciální, $X \sim Exp(n,\ p)$	$\lambda e^{-\lambda x};\ x \in [0, +\infty)$	$1 - e^{-\lambda x}$	$\frac{1}{\lambda}$	$\frac{1}{\lambda^2}$
Normální (Gaussovo), $X \sim Geom(p)$	$\frac{1}{\sigma\sqrt{2\pi}} * e^{\frac{-(x-\mu)^2}{2\sigma^2}}$	$\times$	μ	σ^2

Obrázek 8: Spojité rozdělení

4 Entropie

Entropie diskrétní veličiny

$$\boxed{H_b(X) = -\sum p_i \log_b p_i}$$

Entropie spojité veličiny

$$\boxed{H_b\left(X\right)=-\int\limits_{-\infty}^{+\infty}f\left(x\right)\log_b f\left(x\right)\mathrm{d}x}$$

(b je základ abecedy pro kódová slova, nejčastěji používáme binární abecedu, tedy $b=2$)

Aditivita entropie

$$\begin{aligned}H\left(X,Y\right) &= H\left(X\right)+H\left(Y|X\right)\\ H\left(X,Y\right) &= H\left(X\right)+H\left(Y\right) \text{ (speciálně jen pro nezávislé náhodné veličiny)}\end{aligned}$$

4.1 Sdružená entropie

$$H\left(X,Y\right)=-\sum_{i,j}p_{i,j}\log p_{i,j}$$

(sdružená hustota $p_{i,j}=P\left(X=x_i,\,Y=Y_j\right)$)

4.2 Podmíněná entropie

$$\begin{aligned}H\left(X|Y\right) &= -\sum_{i,j}p\left(x_i,y_i\right)\log p\left(y_j|x_i\right)\\ \mathbb{P}\left(x_i|y_j\right) &= \frac{\mathbb{P}\left(x_i,\,y_j\right)}{\mathbb{P}\left(y_i\right)}\quad\begin{matrix}\text{sdružená hustota}\\ \text{marginální hustota}\end{matrix}\\ \mathbb{P}\left(X,\,Y\right) &= \mathbb{P}\left(X|Y\right)*\mathbb{P}\left(Y\right)\end{aligned}$$

4.3 Vzájemná informace

$$\begin{aligned}I\left(X;\,Y\right) &= H\left(X\right)-H\left(X|Y\right)\\ I\left(X;\,Y\right) &= H\left(Y\right)-H\left(Y|X\right)\\ I\left(X;\,Y\right) &= H\left(X\right)+H\left(Y\right)-H\left(X,\,Y\right)\\ I\left(X;\,Y\right) &= I\left(Y;\,X\right)\\ I\left(X;\,X\right) &= H\left(X\right)\end{aligned}$$

$$I\left(X,\,Y\right)=\sum_{i,\,j}p_{i,j}\log\frac{p_{i,j}}{p_i*p_j}=\ldots=H\left(X\right)-H\left(X|Y\right)$$

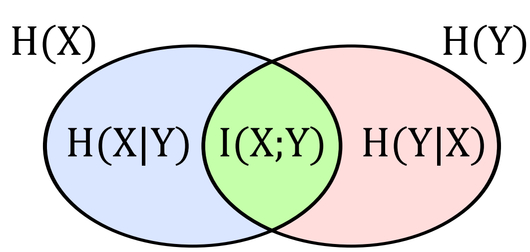

Obrázek 9: Vzájemná informace a entropie (tedy $H\left(X,\,Y\right)$)

4.4 Kódování

Střední délka kódového slova

$$
\begin{aligned}
L(C) &= \mathbb{E}\ell(X) = \sum_i \ell(x_i) * \mathbb{P}(X = x_i) \\
L(C) &\geq H_D(X)
\end{aligned}
$$

Kódování je optimální, pokud se střední délka kódového slova a entropie rovnají ($L(C) = H_D(X)$).

5 Náhodné procesy

Značení procesu

$$X(t,\ \omega) = X_t = X(t)$$

Střední hodnota

$$
\begin{aligned}
\eta_x(t) &= \mathbb{E}X(t) = \int x(t) * f_{X_t}(x)\,\mathrm{d}x \\
&\quad \mathbb{E}X(t) = \sum x_i(t)\,\mathbb{P}(X_t = x_i(t))
\end{aligned}
$$

Pokud je střední hodnota **nezávislá** na t, **je proces stacionární** v průměru. Tedy

$$\eta(t) = \eta_x\ \forall t$$

Střední hodnota integrálu

$$\mathbb{E}\int_a^b X(t)\,\mathrm{d}t = \int_a^b \mathbb{E}X(t)\,\mathrm{d}t$$

Autokorelační funkce

$$
\begin{aligned}
R_{xx}(t_1,\ t_2) &= \mathbb{E}\left[X(t_1) * \overline{X(t_2)}\right] \text{ v } \mathbb{C} \\
&= \mathbb{E}\left[X(t_1) * X(t_2)\right] = \sum_i x_i(t) * P(X(t_1) * X(t_2) = x_i(t)) \text{ v } \mathbb{R}
\end{aligned}
$$

V ukázkovém příkladu se autokorelační funkce spočítala pomocí následujícího „triku“ ($0 \leq t_1 \leq t_2 \leq 2$)

$$
\begin{aligned}
R_x(t_1,\, t_2) &= \mathbb{E}\left[X(t_1) * X(t_2)\right] = 0 * \mathbb{P}(X(t_1) * X(t_2) = 0) + 1 * \mathbb{P}(X(t_1) * X(t_2) = 1) \\
&= \mathbb{P}(X(t_1) * X(t_2) = 1) = \mathbb{P}(X(t_1) = 1,\, X(t_2) = 1) = \\
&= \boxed{\mathbb{P}(t_1 \leq A,\, t_2 \leq A) = \mathbb{P}(A \geq t_1,\, t_2 \geq A) = P(A \geq t_2)}
\end{aligned}
$$

5.1 Exponenciální závody

Spojité, bez paměti (memoryless), bez intenzit.

$$S \sim Exp(\lambda),\, T \sim Exp(\mu)$$

(Náhodné veličiny S a T jsou náhodně rozdělené.)

$$\mathbb{E}\left(S\right)=\frac{1}{\lambda},\,\mathbb{E}\left(T\right)=\frac{1}{\mu}$$

$$\begin{aligned}\mathbb{E}\max\left\{S,\,T\right\} &= \mathbb{E}\left(S\right)+\mathbb{E}\left(T\right)-\mathbb{E}\min\left\{S,\,T\right\}\\ \mathbb{E}\min\left\{S,\,T\right\} &= \frac{1}{\lambda+\mu}\\ \mathbb{P}\left(T<S\right) &= \frac{\mu}{\lambda+\mu}\\ \mathbb{P}\left(S<T\right) &= \frac{\lambda}{\lambda+\mu}\end{aligned}$$

5.1.1 Grafická reprezentace

Často pomocí následujícího diagramu (příklad):

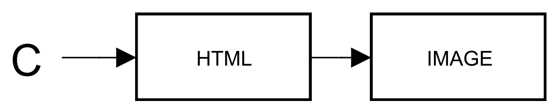

Obrázek 10: Diagram exponenciálních závodů

6 Markovovy řetězce

Matice přechodů

$$\mathbb{P}_{i,j}=p\left(i,\,j\right)=P\left(X_{n+1}=s_j|X_n=s_i\right)=p_{i,j}$$

Řetězec zapisujeme

- diagramem,
- maticí přechodů.

6.1 Stacionární distribuce

- Po čase se některé Markovovy řetězce ustálí v nějakém stavu.
- Rovnovážná distribuce
$$\pi:\,\pi=\pi*\mathbb{P}$$
- Detailní rovnováha
$$\pi_i p_{i,j}=\pi_j p_{j,i}\,\forall i,\,j$$

7 Systémy hromadné obsluhy

Modely:

- $M/M/1$
- $M/M/m$
- $M/G/\infty$

Míra vytížení:

$$\rho = \frac{\lambda}{\mu}$$

(musí být < 1, aby systém pracoval)

Little's law (průměrný počet zákazníků ve frontě):

$$N = \lambda * T$$

8 Statistika

8.1 Konfidenční intervaly

σ^2 známe:

$$\mu \in \left(\overline{X}_n - \mathcal{Z}_{\frac{\alpha}{2}} \frac{\sigma}{\sqrt{n}}; \overline{X}_n + \mathcal{Z}_{\frac{\alpha}{2}} \frac{\sigma}{\sqrt{n}} \right)$$

σ^2 neznáme:

$$\mu \in \left(\overline{X}_n - \mathcal{T}_{\frac{\alpha}{2|n-1}} \frac{\mathcal{S}_n}{\sqrt{n}}; \overline{X}_n + \mathcal{T}_{\frac{\alpha}{2|n-1}} \frac{\mathcal{S}_n}{\sqrt{n}} \right)$$

$|n-1$ je stupeň volnosti studentova rozdělení

9 Ostatní

9.1 Řady

Výpočet řad

$$\begin{aligned} \sum_{n=0}^{\infty} r^n &= \frac{1}{1-r} \\ \sum_{n=0}^{\infty} n * r^n &= \frac{r}{(1-r)^2} \end{aligned}$$

Nekonečná řada:

$$\frac{a_1}{1-q}$$

(a_1 – počátek, q – kvocient)

9.2 Logaritmus

$$\begin{aligned} \log_a(x_1 * x_2) &= \log_a x_1 + \log_a x_2 \\ \log_a\left(\frac{x_1}{x_2}\right) &= \log_a x_1 - \log_a x_2 \\ \log_a x^r &= r * \log_a x \\ \log_a a &= 1 \\ \log_a 1 &= 0 \end{aligned}$$